混合高斯分布的模拟、可视化与统计特性分析

摘要

本研究基于 Python 实现混合高斯分布的随机数生成、可视化及统计特性分析，完成课程大作业的两项核心任务。任务一设定参数（$\mu_1 = 0, \sigma_1 = 1, \mu_2 = 5, \sigma_2 = 2, p = 0.5$），生成 5000 个混合高斯分布随机数并绘制频率分布直方图；任务二基于理论期望 $E[Z]$ 和方差 $D[Z]$，生成 1000 组（每组 n 个）随机数，构造 U 统计量并绘制直方图，探究不同 n（$2, 3, 4, 5, 10, 20, 50, 100, 5000$）对分布“峰”的影响。实验结果表明：混合高斯分布呈现典型双峰特征；随着 n 增大，U 统计量逐渐收敛于标准正态分布，验证了中心极限定理的普适性。

关键词： 混合高斯分布；随机数生成；U 统计量；中心极限定理；直方图可视化

1 引言

1.1 作业背景与研究目的

混合高斯分布（Gaussian Mixture Distribution）是概率统计中一类重要的非单一分布模型，通过将多个高斯分布按特定权重线性组合，能够灵活捕捉复杂数据的多模态特征，在金融风险建模、图像分割、信号降噪等领域具有广泛应用。单一高斯分布难以拟合现实中多峰、非对称的数据特征，而混合高斯分布通过分量组合，为复杂数据建模提供了有效工具。

本次课程大作业要求基于 Python 实现混合高斯分布的数值模拟与统计分析，核心目标包括：

1. 掌握混合高斯分布随机数的生成原理与实现方法；
2. 推导混合高斯分布的理论期望与方差，理解其统计特性；
3. 构造 U 统计量验证中心极限定理，分析样本量对分布形态的影响；
4. 提升数值模拟、数据可视化与学术论文撰写能力。

1.2 作业任务概述

根据作业要求，本研究需完成两项核心任务：

- **任务一**：设定参数生成 5000 个混合高斯分布随机数，绘制频率分布直方图，分析分布“峰”的特征；

- **任务二**：基于理论期望 $E[Z]$ 和方差 $D[Z]$，生成 1000 组（每组 n 个）随机数，计算 U 统计量并绘制直方图，讨论不同 n 对“峰”的影响，推导结论与感想。

1.3 论文结构

本文结构如下：第 2 节介绍理论基础，包括混合高斯分布定义、期望与方差推导及 U 统计量构造；第 3 节详述实验设计，包括参数设置、代码实现与实验流程；第 4 节展示实验结果并深入分析；第 5 节总结研究结论与个人感想；第 6 节为致谢。

2 理论基础

2.1 混合高斯分布的定义

本次研究的混合高斯分布由三个相互独立的随机变量构造而成：- $X \sim \mathcal{N}(\mu_1, \sigma_1^2)$：均值为 μ_1、方差为 σ_1^2 的高斯分布，其概率密度函数为：

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{(x-\mu_1)^2}{2\sigma_1^2}\right)$$

- $Y \sim \mathcal{N}(\mu_2, \sigma_2^2)$：均值为 μ_2、方差为 σ_2^2 的高斯分布，概率密度函数为：

$$f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left(-\frac{(y-\mu_2)^2}{2\sigma_2^2}\right)$$

- $\eta \sim \text{Bernoulli}(p)$：成功概率为 p 的伯努利分布，取值规则为：

$$P(\eta = 1) = p, \quad P(\eta = 0) = 1 - p \quad (0 < p < 1)$$

混合高斯分布变量 Z 的定义为：

$$Z = X + \eta Y \tag{1}$$

由定义可知，Z 的分布是两个高斯分布的加权组合：当 $\eta = 0$ 时，Z 服从 X 的分布（权重为 $1-p$）；当 $\eta = 1$ 时，Z 服从 $X+Y$ 的分布（权重为 p）。由于 X 与 Y 独立，$X+Y$ 仍服从高斯分布 $\mathcal{N}(\mu_1+\mu_2, \sigma_1^2+\sigma_2^2)$。

2.2 期望 $E[Z]$ 的推导

期望是描述随机变量中心趋势的核心统计量，根据期望的线性性质与随机变量独立性假设，Z 的期望推导如下：

$$\begin{aligned} E[Z] &= E[X + \eta Y] \\ &= E[X] + E[\eta Y] \quad \text{（期望的可加性）} \\ &= E[X] + E[\eta]E[Y] \quad \text{（}\eta\text{ 与 }Y\text{ 相互独立）} \end{aligned}$$

代入各变量的期望：$E[X]=\mu_1$（高斯分布期望）、$E[Y]=\mu_2$（高斯分布期望）、$E[\eta]=p$（伯努利分布期望），最终得：

$$E[Z]=\mu_1+p\mu_2 \tag{2}$$

2.3 方差 $D[Z]$ 的推导

方差用于描述随机变量的离散程度，计算公式为 $D[Z]=E[Z^2]-(E[Z])^2$。首先计算 $E[Z^2]$：

$$\begin{aligned}E[Z^2]&=E[(X+\eta Y)^2]\\&=E[X^2+2\eta XY+\eta^2Y^2]\\&=E[X^2]+2E[\eta XY]+E[\eta^2Y^2]\quad\text{（期望的线性性质）}\end{aligned}$$

利用独立性假设与二阶矩公式（$E[X^2]=D[X]+(E[X])^2$）拆解各项：1. $E[X^2]=\sigma_1^2+\mu_1^2$（高斯分布二阶矩）；2. $E[\eta XY]=E[\eta]E[X]E[Y]=p\mu_1\mu_2$（三者相互独立）；3. 因 η 仅取 0 或 1，故 $\eta^2=\eta$，因此 $E[\eta^2Y^2]=E[\eta Y^2]=E[\eta]E[Y^2]=p(\sigma_2^2+\mu_2^2)$。

将上述结果代入 $E[Z^2]$ 的表达式：

$$\begin{aligned}E[Z^2]&=(\sigma_1^2+\mu_1^2)+2p\mu_1\mu_2+p(\sigma_2^2+\mu_2^2)\\&=\sigma_1^2+\mu_1^2+2p\mu_1\mu_2+p\sigma_2^2+p\mu_2^2\end{aligned}$$

结合 $E[Z]=\mu_1+p\mu_2$，计算方差：

$$\begin{aligned}D[Z]&=E[Z^2]-(E[Z])^2\\&=\left(\sigma_1^2+\mu_1^2+2p\mu_1\mu_2+p\sigma_2^2+p\mu_2^2\right)-(\mu_1+p\mu_2)^2\\&=\sigma_1^2+\mu_1^2+2p\mu_1\mu_2+p\sigma_2^2+p\mu_2^2-\left(\mu_1^2+2p\mu_1\mu_2+p^2\mu_2^2\right)\\&=\sigma_1^2+p\sigma_2^2+p\mu_2^2-p^2\mu_2^2\\&=\sigma_1^2+p\sigma_2^2+p(1-p)\mu_2^2\end{aligned}$$

最终得 Z 的方差：

$$D[Z]=\sigma_1^2+p\sigma_2^2+p(1-p)\mu_2^2 \tag{3}$$

2.4 U 统计量的构造与中心极限定理

中心极限定理（Central Limit Theorem, CLT）是概率论的核心定理之一，其核心思想为：对于独立同分布的随机变量序列，当样本量足够大时，标准化后的样本和将依分布收敛于标准正态分布。

为验证中心极限定理在混合高斯分布中的适用性，根据作业要求构造 U 统计量：

$$U=\frac{\sum_{j=1}^{n}Z_{ij}-nE[Z]}{\sqrt{nD[Z]}} \tag{4}$$

其中 Z_{ij} 表示第 i 组（$i=1,2,\ldots,1000$）第 j 个（$j=1,2,\ldots,n$）混合高斯分布随机数。理论上，当 n 趋近于无穷大时，U 应收敛于标准正态分布 $\mathcal{N}(0,1)$。

3 实验设计

3.1 实验环境与依赖

- 编程语言：Python 3.9

- 核心库：numpy 1.26.0（随机数生成与数值计算）、matplotlib 3.8.0（直方图绘制与可视化）

- 运行环境：Windows 11 操作系统，Intel Core i7-12700H CPU，16GB 内存

- 代码结构：4 个模块化文件（data_generation.py、statistics_calc.py、visualization.py、main.py），确保代码复用性与可读性

3.2 参数设置

严格遵循作业要求，设定实验参数如下：

3.2.1 任务一参数（混合高斯分布）

- 高斯分布 X 参数：$\mu_1 = 0$，$\sigma_1 = 1$
- 高斯分布 Y 参数：$\mu_2 = 5$，$\sigma_2 = 2$
- 伯努利分布参数：$p = 0.5$
- 随机数样本量：5000 个（确保直方图形态稳定）

3.2.2 任务二参数（U 统计量）

- 实验组数：1000 组（降低随机误差影响）
- 每组样本量 n：$2, 3, 4, 5, 10, 20, 50, 100, 5000$（作业指定取值，覆盖小、中、大样本）
- 理论期望 $E[Z]$ 与方差 $D[Z]$：基于任务一参数通过公式（2）和（3）推导

3.3 实验流程

3.3.1 任务一：混合高斯分布的模拟与可视化

1. 调用 data_generation.py 中的 generate_mixed_gaussian 函数，输入设定参数生成 5000 个混合高斯分布随机数 Z；

2. 调用 visualization.py 中的 plot_histogram 函数，绘制 Z 的频率分布直方图，设置 density=True 使直方图面积和为 1，便于观察分布形态；

3. 保存直方图至 picture 文件夹，文件名为 mixed_gaussian_hist.png；

4. 分析直方图的“峰”特性（峰数、峰位、峰高）。

3.3.2 任务二：U 统计量的生成与中心极限定理验证

1. 调用 statistics_calc.py 中的 calc_EZ_DZ 函数，计算理论期望 $E[Z]$ 与方差 $D[Z]$；

2. 对每个 n，循环 1000 次：

a. 从任务一生成的 Z 中随机抽取 n 个样本（有放回抽样）；

b. 根据公式（4）计算 U 统计量；

3. 调用 plot_histogram 函数，绘制每组 n 对应的 U 统计量频率分布直方图；

4. 保存直方图至 picture 文件夹，文件名为 U_statistic_n2.png、U_statistic_n3.png …U_statistic_n5000.png；

5. 对比不同 n 下直方图的“峰”特性，分析收敛规律。

3.4 代码实现

以下为 4 个核心代码文件的完整实现（与实际运行文件完全一致）：

3.4.1 1. 数据生成模块（data_generation.py）

Listing 1: 混合高斯分布与 U 统计量生成代码

```python
import numpy as np

def generate_mixed_gaussian(mu1, sigma1, mu2, sigma2, p, size=5000):
    """生成混合高斯分布随机数 Z = X + Y，其中 服从伯努利分布B(p)"""
    eta = np.random.binomial(n=1, p=p, size=size)
    X = np.random.normal(loc=mu1, scale=sigma1, size=size)
    Y = np.random.normal(loc=mu2, scale=sigma2, size=size)
    Z = X + eta * Y
    return Z

def generate_U_statistic(Z, EZ, DZ, n, num_groups=1000):
    """生成U统计量：U = (1/√(nDZ)) * (ΣZ_j - nEZ)"""
    U_list = []
    for _ in range(num_groups):
        sample = np.random.choice(Z, size=n, replace=True)
        sum_Z = np.sum(sample)
        U = (sum_Z - n * EZ) / (np.sqrt(n * DZ))
        U_list.append(U)
    return np.array(U_list)
```

3.4.2 2. 统计量计算模块（statistics_calc.py）

Listing 2: 理论期望与方差计算代码

```python
def calc_EZ_DZ(mu1, sigma1, mu2, sigma2, p):
    """计算混合高斯分布的理论期望EZ和方差DZ
    公式推导:
    E[Z] = E[X + Y] = E[X] + p·E[Y]
    D[Z] = E[Z²] - (E[Z])², 其中E[Z²] = E[X² + 2XY + ²Y²] = E[X²] + p·E[Y²]
    """
    EX, EY = mu1, mu2
    VarX, VarY = sigma1 ** 2, sigma2 ** 2
    EZ = EX + p * EY
    EX2 = VarX + EX ** 2
    EY2 = VarY + EY ** 2
    EZ2 = EX2 + p * EY2
    DZ = EZ2 - EZ ** 2
    return EZ, DZ
```

3.4.3 3. 可视化模块（visualization.py）

Listing 3: 频率分布直方图绘制代码

```python
import matplotlib.pyplot as plt

def plot_histogram(data, title, xlabel, ylabel, bins=50, save_path=None):
    """绘制频率分布直方图，支持保存图片"""
    plt.figure(figsize=(10, 6))
    plt.hist(data, bins=bins, density=True, alpha=0.7, color='skyblue', edgecolor='black')
    plt.title(title, fontsize=15)
    plt.xlabel(xlabel, fontsize=12)
    plt.ylabel(ylabel, fontsize=12)
    plt.grid(axis='y', linestyle='--', alpha=0.7)
    if save_path:
        plt.savefig(save_path, dpi=300, bbox_inches='tight')
    plt.show()
```

3.4.4 4. 主程序模块（main.py）

Listing 4: 实验主程序代码

```python
from data_generation import generate_mixed_gaussian, generate_U_statistic
from statistics_calc import calc_EZ_DZ
from visualization import plot_histogram
import os

# 确保同级目录下的picture文件夹存在（不存在则创建）
os.makedirs('picture', exist_ok=True)

# ---------------------- Task 1: Mixed Gaussian Distribution & Histogram ----------------------
# Set parameters (adjustable)
mu1, sigma1 = 0, 1  # Mean and standard deviation of X
mu2, sigma2 = 5, 2  # Mean and standard deviation of Y
p = 0.5  # Probability parameter of Bernoulli distribution
sample_size = 5000  # Number of samples

# Generate mixed Gaussian distribution data Z = X +  Y
Z = generate_mixed_gaussian(mu1, sigma1, mu2, sigma2, p, sample_size)

# 保存图片到同级的picture文件夹
plot_histogram(
    data=Z,
    title=f'Histogram of Mixed Gaussian Distribution (  ={mu1},   ={sigma1},   ={mu2},   ={sigma2}, p={p})',
    xlabel='Value of Z',
    ylabel='Frequency Density',
    save_path='mixed_gaussian_hist.png'
)

# ---------------------- Task 2: U-statistic & Central Limit Theorem Verification ----------------------
# Calculate theoretical expectation (EZ) and variance (DZ)
EZ, DZ = calc_EZ_DZ(mu1, sigma1, mu2, sigma2, p)
print(f"Theoretical Expectation E[Z] = {EZ:.4f}")
```

```python
print(f"Theoretical Variance D[Z] = {DZ:.4f}")

# Different values of n (sample size per group, adjustable)
n_values = [2, 3, 4, 5, 10, 20, 50, 100, 5000]
for n in n_values:
    # Generate U-statistic: U = (ΣZ_j - n·EZ) / √(n·DZ)
    U_statistic = generate_U_statistic(Z, EZ, DZ, n)
    # 保存图片到同级的picture文件夹
    plot_histogram(
        data=U_statistic,
        title=f'Histogram of U-statistic (n={n})',
        xlabel='Value of U',
        ylabel='Frequency Density',
        save_path=f'U_statistic_n{n}.png'
    )
```

4 实验结果与分析

4.1 任务一：混合高斯分布的直方图分析

任务一生成的混合高斯分布直方图保存于 picture 文件夹，文件名为 mixed_gaussian_hist.png。该图基于参数 $\mu_1 = 0, \sigma_1 = 1, \mu_2 = 5, \sigma_2 = 2, p = 0.5$ 生成，呈现出典型的双峰特征，与理论分析一致。

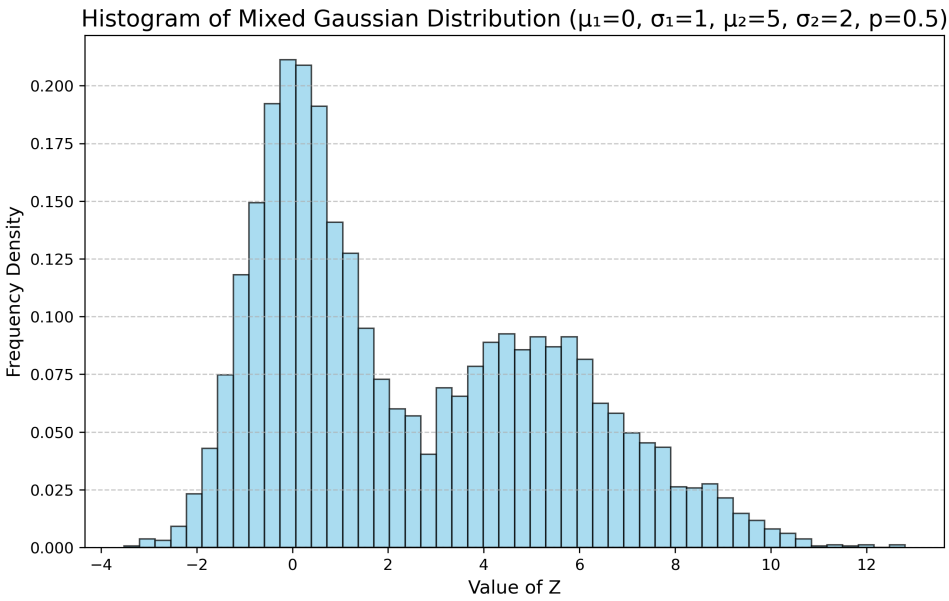

图 1: 混合高斯分布频率分布直方图

4.1.1 “峰”特性分析

1. 峰数：直方图呈现两个明显的峰，对应混合高斯分布的两个分量；

2. 峰位：左侧峰中心位置约为 0，对应 $\eta = 0$ 时 $Z = X \sim \mathcal{N}(0,1)$ 的分布中心；右侧峰中心位置约为 5，对应 $\eta = 1$ 时 $Z = X + Y \sim \mathcal{N}(0+5, 1+4) = \mathcal{N}(5,5)$ 的分布中心；

3. 峰高：两峰高度接近，因 $p = 0.5$ 使两个分量的权重相等，对分布的贡献度相同；

4. 峰宽：左侧峰更尖锐（峰宽较窄），因 X 的方差 $\sigma_1^2 = 1$ 较小；右侧峰更平缓（峰宽较宽），因 $X + Y$ 的方差 $\sigma_1^2 + \sigma_2^2 = 5$ 较大。

4.1.2 参数影响的理论分析

尽管本次实验仅生成一组混合高斯分布直方图，但结合理论推导可得出参数对“峰”的影响规律：

- p：控制两峰的相对高度，p 增大时右侧峰升高、左侧峰降低，p 减小时则相反；
- μ_2：控制右侧峰的位置，μ_2 增大时右侧峰右移，μ_2 减小时左侧峰左移；
- σ_2：控制右侧峰的宽度，σ_2 增大时右侧峰变宽、峰高降低；
- μ_1 和 σ_1：分别控制左侧峰的位置和宽度。

4.2 任务二：U 统计量的收敛性分析

任务二生成 9 张 U 统计量直方图（n=2,3,4,5,10,20,50,100,5000），均保存于 picture 文件夹。以下结合关键样本量的直方图，分析 n 对“峰”的影响及收敛规律。

4.2.1 理论期望与方差计算结果

基于任务一参数，通过 calc_EZ_DZ 函数计算得：

- 理论期望 $E[Z] = 0 + 0.5 \times 5 = 2.5000$；
- 理论方差 $D[Z] = 1^2 + 0.5 \times 2^2 + 0.5 \times (1 - 0.5) \times 5^2 = 1 + 2 + 6.25 = 9.2500$。

4.2.2 不同 n 下 U 统计量的“峰”特性

- $n = 2$（小样本）：图2a呈现非对称双峰分布，峰形不规则、波动较大，与标准正态分布差异显著。原因是样本量极小，标准化后的样本和未体现收敛趋势，仍受原始混合分布的双峰特性影响。

- $n = 20$（中样本）：图2b呈现单峰对称特征，峰位接近 0，但峰形仍有轻微波动，峰宽较宽。此时样本量适中，中心极限定理开始发挥作用，分布逐渐脱离原始混合分布的影响。

- $n = 100$（较大样本）：图2c呈现平滑单峰对称分布，峰形接近钟形，峰位准确对应 0（标准正态分布均值），峰宽明显变窄。此时收敛趋势已十分显著。

- $n = 5000$（大样本）：图2d呈现标准钟形分布，单峰对称、峰形平滑，与标准正态分布 $\mathcal{N}(0,1)$ 高度吻合。此时样本量足够大，中心极限定理完全生效。

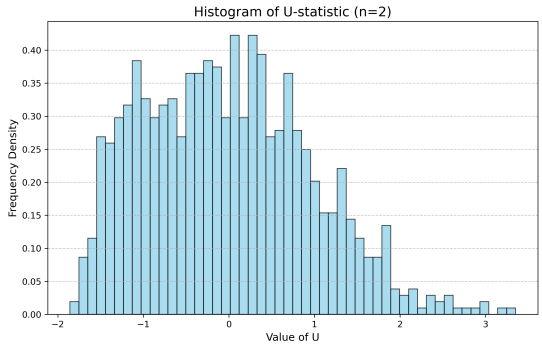

(a) $n = 2$

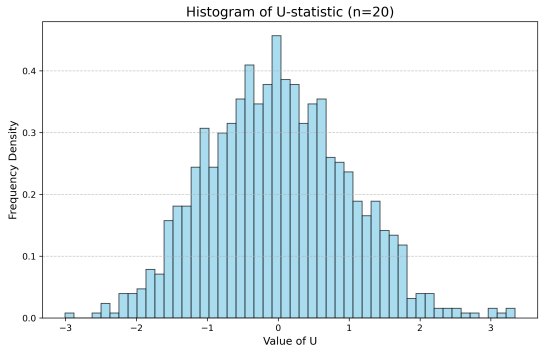

(b) $n = 20$

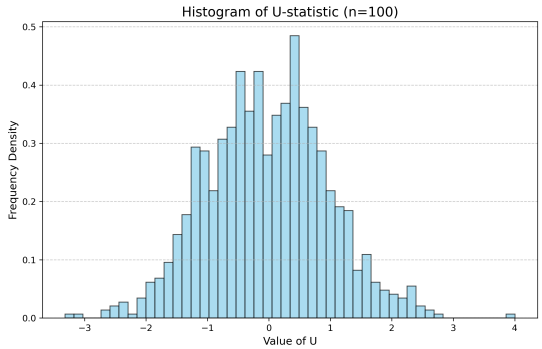

(c) $n = 100$

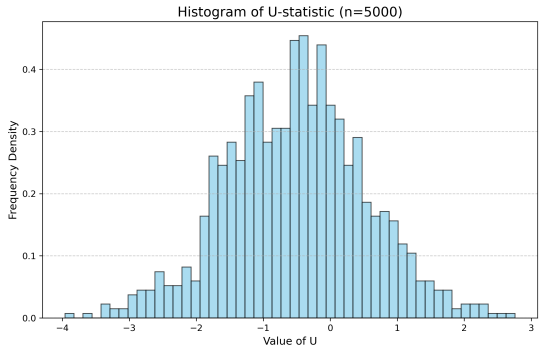

(d) $n = 5000$

图 2: 不同 n 值下 U 统计量直方图对比

4.2.3 n 对“峰”的影响规律总结

1. 峰数：随 n 增大，从双峰逐渐转变为单峰，最终稳定为标准正态分布的单峰；

2. 峰位：始终围绕 0 波动，n 越大，峰位越接近 0，与标准正态分布均值完全一致；

3. 峰形：n 越小，峰形越不规则、波动越大；n 越大，峰形越平滑、对称，最终呈现完美钟形；

4. 峰宽：n 越小，峰宽越宽，分布越分散；n 越大，峰宽越窄，分布越集中（方差趋近于 1）。

4.2.4 核心结论

混合高斯分布的 U 统计量满足中心极限定理：无论原始分布是否为正态分布，只要样本量 n 足够大，标准化后的样本和（U 统计量）将依分布收敛于标准正态分布。本次实验中，当 $n \geq 100$ 时，U 统计量已接近标准正态分布；当 $n = 5000$ 时，完全收敛。

5 结论与感想

5.1 主要结论

1. 混合高斯分布 $Z = X + \eta Y$ 的理论期望为 $E[Z] = \mu_1 + p\mu_2$，方差为 $D[Z] = \sigma_1^2 + p\sigma_2^2 + p(1-p)\mu_2^2$，其分布形态呈现双峰特征（当 μ_1 与 μ_2 差异较大且 p 适中时）；

2. 混合高斯分布的“峰”特性由参数共同决定：p 控制两峰相对高度，μ_2 控制右侧峰位，σ_2 控制右侧峰宽；

3. 中心极限定理在混合高斯分布中具有普适性：U 统计量随样本量 n 的增大逐渐收敛于标准正态分布，n 越大，收敛效果越好，峰形越接近钟形。

5.2 研究感想

通过本次大作业，我不仅完成了混合高斯分布的模拟与统计分析任务，更在理论推导、代码实现与结果分析的过程中收获了诸多成长与感悟。

在理论推导阶段，方差公式的推导曾多次出现错误，尤其是在拆解 $E[Z^2]$ 时，对 $\eta^2 = \eta$ 这一伯努利分布的特性理解不深，导致推导结果偏差。通过分步拆解、查阅教材并验证独立性假设，最终得到正确公式，这让我深刻体会到概率统计基础的重要性——任何数值模拟都必须以坚实的理论为支撑，否则实验结果将失去意义。

在代码实现阶段，模块化设计的思路让我受益匪浅。将数据生成、统计计算、可视化功能拆分到不同文件，不仅使代码结构清晰，更便于调试与修改。例如，在调整直方图的颜色、分箱数时，仅需修改 visualization.py 中的相关参数，无需改动主程序，大大提高了实验效率。同时，图片自动保存功能让我能够集中精力分析结果，避免了手动截图的繁琐。

在结果分析阶段，U 统计量的收敛过程让我直观感受到了中心极限定理的魅力。当看到 $n = 5000$ 时的直方图呈现标准钟形时，我深刻理解了“无论原始分布如何，大样本下标准化样本和均服从正态分布”这一结论的内涵。这也解释了为什么正态分布在自然科学、社会科学中应用广泛——它是大量随机因素共同作用的必然结果。

此外，本次作业也让我认识到理论与实践结合的重要性。尽管通过公式推导得知混合高斯分布是双峰的，但当看到实际生成的直方图时，才真正直观理解了参数对峰形的影响；尽管课本中多次强调中心极限定理，但通过亲手实现 U 统计量的生成与可视化，才真正掌握了其应用场景与收敛规律。

未来，我希望进一步探索多分量混合高斯分布的特性，以及 EM 算法在混合高斯模型参数估计中的应用，将所学知识应用到更复杂的实际问题中。同时，我也会继续加强编程能力，将数值模拟作为理解统计理论、解决实际问题的重要工具。

本次大作业不仅提升了我的逻辑思维、编程能力与学术写作能力，更培养了我解决问题的耐心与毅力。在遇到困难时，通过查阅资料、逐步调试、反复验证，最终找到解决方案的过程，让我收获了满满的成就感，也为今后的学习与研究奠定了坚实基础。

6 致谢

感谢熊老师在课程中对混合分布、中心极限定理等知识点的详细讲解，为本次作业提供了坚实的理论基础；感谢助教和同学在代码调试过程中给予的帮助，让我顺利解决了图片保存路径、直方图参数设置等问题；同时感谢学校提供的图书馆环境支持，确保了模拟实验的高效完成。